

Q1

1. השתמש בקובץ haifa_res.xls. התאם מודל ליניארי של ההוצאה החודשית כפונקציה של ההכנסה החודשית המובחנת לפי מין. שקול גם משתנה אינדיקטור למין וגם איבר אינטראקציה.

א. הצג את המודל התיאורטי ופרט את ההנחות. הצג מודל מותאם ואת הסיכום שלו. האם המודל מובהק?

המודל התיאורטי כולל משתנה אינדיקטור למין ואיבר אינטראקציה בין הכנסה למין:

$$Y_i = \beta_0 + \beta_1 X_i + \beta_2 D_i + \beta_3 (X_i \cdot D_i) + \epsilon_i$$

כאשר X_i ההכנסה החודשית $D_i = 1$ אם גבר, $D_i = 0$ אם אישה. המודל מתפרק לשני משוואות:

- נשים $Y_i = \beta_0 + \beta_1 X_i + \epsilon_i$

- גברים $Y_i = (\beta_0 + \beta_2) + (\beta_1 + \beta_3)X_i + \epsilon_i$

הנחות המודל:

a. נורמליות $\epsilon_i \sim N(0, \sigma^2)$ ולכל i

b. שוויון שוננויות $\text{Var}(\epsilon_i) = \sigma^2$ קבוע

c. עצמאות $\text{Cov}(\epsilon_i, \epsilon_j) = 0$ לכל $i \neq j$

d. לינאריות: הקשר בין ההכנסה להוצאות לינארי בפרמטרים

OLS Regression Results						
Dep. Variable:	spend		R-squared:	0.727		
Model:	OLS		Adj. R-squared:	0.723		
Method:	Least Squares		F-statistic:	174.0		
Date:	Thu, 14 May 2026		Prob (F-statistic):	5.33e-55		
Time:	21:41:02		Log-Likelihood:	-362.83		
No. Observations:	200		AIC:	733.7		
Df Residuals:	196		BIC:	746.9		
Df Model:	3					
Covariance Type:	nonrobust					
	coef	std err	t	P> t	[0.025	0.975]
Intercept	0.0283	0.520	0.055	0.957	-0.996	1.053
income	0.9885	0.063	15.708	0.000	0.864	1.113
sex	-0.9705	0.775	-1.252	0.212	-2.499	0.558
income:sex	0.1188	0.092	1.291	0.198	-0.063	0.300
Omnibus:	0.594		Durbin-Watson:	2.016		
Prob(Omnibus):	0.743		Jarque-Bera (JB):	0.371		
Skew:	0.091		Prob(JB):	0.831		
Kurtosis:	3.107		Cond. No.	80.4		

המודל האמוד:

$$\hat{Y}_i = 0.028 + 0.989X_i - 0.971D_i + 0.119(X_i \cdot D_i)$$

מובהקות המודל:


- $p < 10^{-54}$, $F(3,196) = 174.0$ המודל מובהק מאוד.
- $R^2 = 0.727$ המודל מסביר כ 72.7% מהשונות בהוצאות.

פרשנות המקדמים:

- $\hat{\beta}_1 = 0.989$ כל אלף ש"ח הכנסה נוספת מגדילה את ההוצאה ב-989 ש"ח אצל נשים. מובהק ($p < 0.001$).
- $\hat{\beta}_2 = -0.971$ הפרש החותך בין גברים לנשים. לא מובהק ($p = 0.212$).
- $\hat{\beta}_3 = 0.119$ הפרש השיפוע בין גברים לנשים. לא מובהק ($p = 0.198$).

המסקנה: ההכנסה מסבירה היטב את ההוצאות, אך לא נמצא הבדל מובהק בין גברים לנשים לא בחותך ולא בשיפוע.

ב. שרטט את התוצאות (שורה אחת לגברים ואחרת לנשים).



מהגרף ניתן לראות כי שני קווי הרגרסיה כמעט מקבילים — השיפועים דומים מאוד לגברים ולנשים, בעקביות עם המסקנה מסעיף א שאיבר האינטראקציה אינו מובהק. כמו כן, החותכים קרובים זה לזה, כלומר לא נמצא הבדל משמעותי בין המינים בהוצאות החודשיות בהינתן רמת הכנסה זהה.

2. בצע בדיקה סטטיסטית כדי לבדוק האם הקשר בין הכנסה להוצאות שונה לפי מין. נסח את ההשערה הנבדקת. הצג את סטטיסטיקת הבדיקה. דון בתוצאות.

הקשר בין הכנסה להוצאות שונה לפי מין אם ואחד בלבד אם השיפוע שונה בין גברים לנשים, כלומר אם איבר האינטראקציה מובהק. השערות המבחן:

$$H_0 : \beta_3 = 0$$

$$H_1 : \beta_3 \neq 0$$

תחת H_0 , סטטיסטי המבחן מתפלג לפי התפלגות t של סטודנט:

$$t_s = \frac{\hat{\beta}_3}{\widehat{SD}(\hat{\beta}_3)} \sim_{H_0} t(n - p)$$

t-statistic:	1.2914
t-critical ($\alpha=0.05$, two-tailed):	± 1.9721
p-value:	0.1981
df:	196
Reject H_0 ?	False

מתקבל $t_s = 1.291$ עם $t_c = 1.972$, $df = 196$ ו $p - value = 0.198 > \alpha = 0.05$. מאחר ש $|t_s| < t_c$, לא דוחים את H_0 אין עדות סטטיסטית לכך שהקשר בין הכנסה להוצאות שונה בין גברים לנשים.

3. השתמש בגישה הטובה ביותר הגלובלית עם קריטריוני R בריבוע המותאמים כדי לבחור את המודל הטוב ביותר. סכם את התוצאות שלך.

features	formula	adj_r2
(income,)	spend ~ income	0.7233
(income, sex, income:sex)	spend ~ income + sex + income:sex	0.7228
(income, income:sex)	spend ~ income + income:sex	0.7220
(income, sex)	spend ~ income + sex	0.7219
(sex, income:sex)	spend ~ sex + income:sex	0.3770
(income:sex,)	spend ~ income:sex	0.0744
(sex,)	spend ~ sex	-0.0007

נבדקו כל תת-הקבוצות האפשריות של המשתנים. המודל הטוב ביותר לפי $\bar{R}^2$ הוא:

$$\hat{Y}_i = \beta_0 + \beta_1 X_i + \epsilon_i$$

עם $\bar{R}^2 = 0.723$. המסקנה היא שהוספת משתנה המין ואיבר האינטראקציה אינה משפרת את המודל — ההכנסה לבדה מספיקה לחיזוי ההוצאות.

4. השתמש באלגוריתמים שלבים, אחורה וקדימה עם קריטריוני AIC כדי לבחור את המודל הטוב ביותר. סכם את התוצאות. עבור כל שיטה, הצג את המודל ההתחלתי והסופי. האם המודל הטוב ביותר שונה כפונקציה של שיטת הבחירה?

Forward	Initial:	intercept only, final:	['income'], AIC:	731.36
Backward	initial:	['income', 'sex', 'income:sex'], final:	['income'], AIC:	731.36
Stepwise	initial:	intercept only, final:	['income'], AIC:	731.36

שלוש השיטות מובילות לאותו מודל סופי:

$$\hat{Y}_i = \beta_0 + \beta_1 X_i + \epsilon_i$$

אלגוריתם Forward התחיל ממודל ריק והוסיף את income בלבד. אלגוריתם Backward התחיל מהמודל המלא והוריד שלב-שלב את sex ואת איבר האינטראקציה. אלגוריתם Stepwise התחיל ממודל ריק והגיע לאותה תוצאה. המודל הטוב ביותר אינו תלוי בשיטת הבחירה — בכלן ההכנסה לבדה מסבירה את ההוצאות בצורה האופטימלית לפי קריטריון אקאיקה.

5. השתמשו באלגוריתם LASSO המרפה (עם CV פי 10 לבחירת פרמטר הכוונון) כדי למצוא את המודל הטוב ביותר. הציגו את המודל הסופי. דווחו והשוו את תוצאותיכם למודל הרגרסיה השלבית הטוב ביותר של קריטריון AIC.

אלגוריתם Relaxed LASSO פועל בשני שלבים:

a. שלב הבחירה — מריצים LASSO רגיל עם פרמטר רגולריזציה λ שנבחר באמצעות fold CV-10. שלב זה מזהה אילו משתנים נכנסים למודל (אלה שמקדמיהם אינם אפס).

b. שלב ההרפיה — מריצים OLS רגיל רק על המשתנים שנבחרו בשלב 1, ללא רגולריזציה. כך מקבלים אומדנים לא-מוטים למקדמים שנבחרו.

היתרון: LASSO רגיל מצמצם את המקדמים לכיוון אפס ולכן יוצר הטיה. ב Relaxed LASSO מנצלים את LASSO לבחירת משתנים בלבד, ואז משתמשים ב OLS לאמידה ללא הטיה.

הערה חשובה: LASSO רגיש לסקאלת המשתנים, מאחר שהקנס $\lambda \sum |\beta_j|$ מיושם באופן אחיד על כל המקדמים. משתנה

עם סקאלה גדולה יקבל מקדם קטן באופן יחסי, ולכן ייוצר עיוות בבחירת המשתנים. לכן לפני הרצת LASSO מבצעים

סטנדרטיזציה של המשתנים — נורמליזציה לממוצע 0 וסטיית תקן 1.

Best lambda (CV):	0.0849
LASSO coefficients (standardized):	{'income': np.float64(2.334), 'sex': np.float64(0.0), 'income:sex': np.float64(0.0)}
Selected variables:	['income']

OLS Regression Results						
Dep. Variable:	spend		R-squared:	0.725		
Model:	OLS		Adj. R-squared:	0.723		
Method:	Least Squares		F-statistic:	521.1		
Date:	Fri, 15 May 2026		Prob (F-statistic):	2.34e-57		
Time:	18:05:02		Log-Likelihood:	-363.68		
No. Observations:	200		AIC:	731.4		
Df Residuals:	198		BIC:	738.0		
Df Model:	1					
Covariance Type:	nonrobust					
	coef	std err	t	P> t	[0.025	0.975]
Intercept	-0.4139	0.385	-1.076	0.283	-1.173	0.345
income	1.0439	0.046	22.828	0.000	0.954	1.134
Omnibus:	1.106		Durbin-Watson:	1.999		
Prob(Omnibus):	0.575		Jarque-Bera (JB):	0.780		
Skew:	0.116		Prob(JB):	0.677		
Kurtosis:	3.199		Cond. No.	31.0		

תוצאות אלגוריתם Relaxed LASSO:

- פרמטר הכונון שנבחר ב CV: $\lambda = 0.0849$
 - בשלב הבחירה, LASSO השאיר משתנה אחד בלבד — income. המקדמים של sex ושל איבר האינטראקציה אופסו.
 - בשלב ההרפיה, OLS על המשתנה שנבחר נתן $\bar{R}^2 = 0.723$ וערך AIC של 731.4.
- השוואה למודל Stepwise AIC:
- Stepwise AIC בחר רק את income, עם ערך AIC של 731.36.
 - Relaxed LASSO הגיע לאותו מודל בדיוק, עם ערך AIC של 731.4.
 - שתי השיטות מסכימות שההכנסה היא המשתנה המסביר היחיד הדרוש לחיזוי ההוצאות, וששאר המשתנים אינם תורמים מובהקית, בעקביות עם תוצאות סעיפים 1, 2, 3 ו-4.
- שתי השיטות הביאו לאותו מודל סופי — המודל הפשוט עם income בלבד. זוהי תוצאה מבוקשת, מאחר שהיא מאשרת ששיטות שונות לבחירת משתנים מצביעות על אותו מבנה אופטימלי. בכך, לא נוצרת בעיה של הפרת עקרון ההיררכיה, ולא נשאר משתנה מיותר במודל.

קראו את קובץ `psych_data.txt`. הוא מכיל נתונים על 999 סטודנטים מחיפה, תל אביב וירושלים שניגשו לבחינה הפסיכומטרית. המשתנים הם:

- `psych` - ציון הבחינה (ערך שלם בין 200 ל-800)
- `city` - העיר בה ניגש הסטודנט לבחינה (חיפה, תל אביב וירושלים)
- `income` - ההכנסה החודשית המדווחת של משפחת הסטודנט (באלפי ש"ח)
- `age` - גיל הסטודנט בעת ניגש לבחינה

המשימה שלנו היא למצוא את המודל הטוב ביותר האפשרי שחוזר את ציוני הבחינה הפסיכומטרית באמצעות הכנסה משפחתית, עיר וגיל.


1. קראו את הקובץ וספקו סיכום תמציתי של הנתונים. הן חזותי והן מספרי.


head()				
	psych	income	city	age
0	521	8.2600	Haifa	26
1	568	18.1200	Haifa	35
2	672	17.7800	Haifa	30
3	587	13.0300	Haifa	25
4	408	4.9600	Haifa	27

info()			
RangeIndex: 999 entries, 0 to 998			
#	Column	Non-Null Count	Dtype
0	psych	999 non-null	int64
1	income	999 non-null	float64
2	city	999 non-null	object
3	age	999 non-null	int64
dtypes:		float64(1), int64(2), object(1)	

describe()			
	psych	income	age
count	999.0000	999.0000	999.0000
mean	542.9660	14.0537	29.9610
std	81.2454	5.7135	4.1405
min	291.0000	2.2000	18.0000
25%	488.0000	10.1100	27.0000
50%	540.0000	13.2200	30.0000
75%	597.0000	17.0900	33.0000
max	800.0000	44.8100	42.0000

['city'].value_counts()	
city	count
Haifa	333
TLV	333
Jerusalem	333





הנתונים כוללים 999 תצפיות, מאוזנות בין שלוש הערים — 333 סטודנטים בכל אחת מחיפה, תל אביב וירושלים. אין ערכים חסרים.

סיכום מספרי:

- psych — ממוצע 543, סטיית תקן 81, טווח 291 עד 800.
- income — ממוצע 14.05 אלפי ש"ח, סטיית תקן 5.71, טווח 2.2 עד 44.8. ההתפלגות אסימטרית ימינה.
- age — ממוצע 30, סטיית תקן 4.14, טווח 18 עד 42. ההתפלגות מרוכזת סביב גיל 30.

סיכום חזותי:

- ההתפלגות של psych קרובה לנורמלית, ההתפלגות של income אסימטרית ימינה, וההתפלגות של age קרובה לנורמלית עם ריכוז ברור סביב גיל 30.
- בהשוואת psych בין הערים נראים הבדלים קטנים בלבד — חיפה עם חציון מעט גבוה יותר, אך החפיפה בין הקבוצות גדולה.
- בגרף הפיזור של psych מול income נראה קשר חיובי לא-ליניארי, בעל צורה קעורה — הציון עולה במהירות בהכנסות נמוכות ומתמתן בהכנסות גבוהות. תופעה זו תהיה רלוונטית לסעיף 3 שבו נשקול טרנספורמציות לא-ליניאריות של income.
- בגרף הפיזור של psych מול age לא נראה קשר ברור — נראה ענן פיזור ללא מגמה.

2. השתמש רק במשתנים הזמינים, ללא אינטראקציות, כדי למצוא את המודל הטוב ביותר באמצעות גישת כל תת-הקבוצות (הטוב ביותר הגלובלי) עם קריטריוני $\bar{R}^2$ בריבוע המותאמים. סכם את התוצאות. הצג במפורש את המצב הטוב ביותר.

features	formula	adj_r2
(income, C(city))	psych ~ income + C(city)	0.6430
(income, C(city), age)	psych ~ income + C(city) + age	0.6426
(income,)	psych ~ income	0.5191
(income, age)	psych ~ income + age	0.5189
(C(city),)	psych ~ C(city)	0.0263
(C(city), age)	psych ~ C(city) + age	0.0258
(intercept only,)	psych ~ 1	-0.0000
(age,)	psych ~ age	-0.0005

נבדקו כל תת-הקבוצות האפשריות של המשתנים הזמינים — סך הכל 8 מודלים. המודל הטוב ביותר לפי $\bar{R}^2$ הוא:


$$Y_i = \beta_0 + \beta_1 \cdot \text{income}_i + \beta_2 \cdot D_{\text{Jerusalem},i} + \beta_3 \cdot D_{\text{TLV}} + \epsilon_i$$

עם . המודל מסביר כ-64% מהשונות בציוני הפסיכומטרי.

תובנות מהטבלה:

- income הוא המשתנה הדומיננטי — לבדו הוא נותן $\bar{R}^2$, ועם הוספת city קופץ ל-0.643.
- age כמעט לא תורם — הוספתו למודל המנצח מורידה את $\bar{R}^2$ מ 0.643 ל 0.6426, ירידה זניחה. זה עקבי עם הניתוח החזותי בסעיף 1 שבו לא נראה קשר ברור בין age ל psych.
- city לבדה מסבירה כ-2.6% בלבד מהשונות, מה שמראה שעיקר ההבדל בין הערים נובע מהכנסה ולא מהעיר עצמה.

3. חבר את כל האינטראקציות הזוגיות בין עיר להכנסה, וקח בחשבון פונקציות לא לינאריות של הכנסה. אילו טרנספורמציות לא לינאריות הן סבירות יותר? קעורות או קמורות? בהתאם לתשובתך, הוסף טרנספורמציות אלו כמשתנים חדשים למערך הנתונים שלך.



Correlation with psych:	
income:	0.7208
log(income):	0.7298
sqrt(income):	0.7325

Variables added to the dataset:

- log_income (concave transformation)
- sqrt_income (concave transformation)
- city x income interactions will be handled via the formula C(city):income in later sections

Dataframe columns:

['psych', 'income', 'city', 'age', 'log_income', 'sqrt_income']

First few rows:

	psych	income	city	age	log_income	sqrt_income
0	521	8.2600	Haifa	26	2.114	2.8740
1	568	18.1200	Haifa	35	2.8970	4.2568
2	672	17.7800	Haifa	30	2.8781	4.2166
3	587	13.0300	Haifa	25	2.5673	3.6097
4	408	4.9600	Haifa	27	1.6014	2.2271

בסעיף 1 ראינו בגרף הפיזור של psych מול income קשר חיובי לא-ליניארי בעל צורה קעורה — הציון עולה במהירות בהכנסות נמוכות ומתמתן בהכנסות גבוהות. מבחינה אינטואיטיבית, זוהי "תשואה פוחתת": משפחה שמגדילה את הכנסתה מ 5 ל 10 אלף ש"ח יכולה לממן הרבה יותר חוגי הכנה והעשרה, בעוד שמשפחה שמגדילה את הכנסתה מ 30 ל 35 אלף תוסיף שיעור פרטי נוסף שכבר לא משנה הרבה.

לכן הטרנספורמציות הסבירות הן קעורות — פונקציות עם נגזרת שנייה שלילית. דוגמאות מוכרות הן ו-
נוסיף שני משתנים חדשים לדאטה:

- $\log_income$ — לוגריתם טבעי של ההכנסה.

- $\sqrt{income}$ — שורש ריבועי של ההכנסה.

השוואת המתאמים עם psych:

- $r = 0.7208 : income$

- $r = 0.7298 : \log(income)$

- $r = 0.7325 : \sqrt{income}$

שתי הטרנספורמציות הקעורות מניבות מתאם גבוה יותר מאשר income המקורי, מה שמאשר את הצורך בטרנספורמציה לא-ליניארית. $\sqrt{income}$ נותן את המתאם הגבוה ביותר.

בנוסף, השאלה דורשת אינטראקציות זוגיות בין city ל income. מאחר שבחרנו להחליף את income בטרנספורמציה הקעורה $\sqrt{income}$ (שמספקת מתאם גבוה יותר עם psych ועקבית עם צורת הקשר שזיהינו), האינטראקציות יוכנסו דרך $C(city):\sqrt{income}$. שילוב של $C(city):income$ ו $C(city):\sqrt{income}$ באותו מודל אינו אפשרי בגלל מולטיקוליניאריות חריפה.

4. בחר את המודל הטוב ביותר באמצעות (1) AIC מדורג ו-(2) CV ללא תוספת (MSE). השווה את התוצאות. בצע אבחון מודל של המודל הסופי.

נבחר את המודל הטוב ביותר באמצעות שתי שיטות עצמאיות ונשווה את התוצאות:

a. Stepwise AIC — אלגוריתם שלבי שמוסיף ומסיר משתנים בהתאם לקריטריון AIC.


b. Leave-One-Out CV — מסירים תצפית אחת בכל פעם, מאמנים את המודל על השאר, וחוזים את התצפית שהוסרה. ה-MSE הוא הממוצע של ריבועי השגיאות. המודל עם ה-MSE הנמוך ביותר הוא הזוכה.

המשתנים המועמדים: $\sqrt{income}$ (טרנספורמציה קעורה מסעיף 3), age, C(city), ואיבר האינטראקציה $C(city):\sqrt{income}$. בחרנו ב $\sqrt{income}$ מבין שתי הטרנספורמציות הקעורות מאחר שהוא נתן את המתאם הגבוה ביותר עם psych. לא ניתן לכלול את $\log_income$, income, ו $\sqrt{income}$ יחד באותו מודל בגלל מולטיקוליניאריות.

Stepwise AIC	final features:	['sqrt_income', 'C(city)', 'C(city):sqrt_income']
Stepwise AIC	final AIC:	10510.64

formula	features	LOO_MSE
psych ~ sqrt_income + C(city) + C(city):sqrt_income	(sqrt_income, C(city), C(city):sqrt_income)	2171.4062
psych ~ sqrt_income + C(city) + age + C(city):sqrt_income	(sqrt_income, C(city), age, C(city):sqrt_income)	2175.4915
psych ~ sqrt_income + C(city)	(sqrt_income, C(city))	2205.7529
psych ~ sqrt_income + C(city) + age	(sqrt_income, C(city), age)	2209.9648
psych ~ sqrt_income	(sqrt_income,)	3067.3697
psych ~ sqrt_income + age	(sqrt_income, age)	3070.9995
psych ~ C(city)	(C(city),)	6446.3620
psych ~ C(city) + age	(C(city), age)	6455.4994
psych ~ 1	()	6607.4325
psych ~ age	(age,)	6616.2319

OLS Regression Results						
Dep. Variable:	psych		R-squared:	0.675		
Model:	OLS		Adj. R-squared:	0.673		
Method:	Least Squares		F-statistic:	411.7		
Date:	Fri, 15 May 2026		Prob (F-statistic):	3.87e-239		
Time:	23:06:59		Log-Likelihood:	-5249.3		
No. Observations:	999		AIC:	1.051e+04		
Df Residuals:	993		BIC:	1.054e+04		
Df Model:	5					
Covariance Type:	nonrobust					
	coef	std err	t	P> t	[0.025	0.975]
Intercept	204.0117	12.804	15.933	0.000	178.885	229.138
C(city)[T.Jerusalem]	-17.1923	19.052	-0.902	0.367	-54.580	20.195
C(city)[T.TLV]	8.9895	18.987	0.473	0.636	-28.270	46.249
sqrt_income	104.9860	3.727	28.169	0.000	97.672	112.300
C(city)[T.Jerusalem]:sqrt_income	-11.4357	5.353	-2.136	0.033	-21.940	-0.931
C(city)[T.TLV]:sqrt_income	-22.3745	5.053	-4.428	0.000	-32.291	-12.458
Omnibus:	1.532		Durbin-Watson:	1.942		
Prob(Omnibus):	0.465		Jarque-Bera (JB):	1.430		
Skew:	-0.089		Prob(JB):	0.489		
Kurtosis:	3.055		Cond. No.	78.4		



השוואת השיטות:

- Stepwise AIC בחר: $\text{sqrt_income} + C(\text{city}) + C(\text{city}):\text{sqrt_income}$, $\text{AIC} = 10510.64$.
- LOO-CV בחר באותו מודל בדיוק, $\text{LOO-MSE} = 2171.41$.
- שתי השיטות מסכימות על אותו מודל. המודל עומד בעקרון ההיררכיה.
- מאפייני המודל הסופי:
- $R^2 = 0.675$ המודל מסביר כ-67.5% מהשונות.
- $p < 10^{-238}$, $F = 411.7$ מובהק מאוד.
- sqrt_income ואיברי האינטראקציה מובהקים. האפקטים העיקריים של $C(\text{city})$ נכללים בגלל ההיררכיה.
- פרשנות: הקשר בין הכנסה לציון קעור (תשואה פוחתת), והשיפוע משתנה בין הערים.
- אבחון המודל:

• Residuals vs Fitted — פיזור אקראי סביב 0, ליניאריות תקינה.

• Q-Q plot — הנקודות על הקו, נורמליות תקינה.

• Scale-Location — פיזור אחיד, שוויון שונויות מתקיים.

• היסטוגרמה — צורת פעמון סימטרית.

מסקנה: כל ההנחות של רגרסיה ליניארית מתקיימות.

5. השתמש באלגוריתם LASSO המרפה (עם CV פי 10 לבחירת פרמטר הכוונון) כדי למצוא את המודל הטוב ביותר. דווח והשווה את תוצאותיך למודל הרגרסיה המדרגית הטוב ביותר של קריטריון AIC.

אלגוריתם Relaxed LASSO פועל בשני שלבים:

a. שלב הבחירה — מריצים LASSO עם פרמטר רגולריזציה λ שנבחר באמצעות CV-10 fold. שלב זה מזהה אילו משתנים נכנסים למודל.

b. שלב ההרפיה — מריצים OLS רגיל רק על המשתנים שנבחרו, ללא רגולריזציה. כך מקבלים אומדנים לא-מוטים. בדומה לסעיף 1.5, נבצע סטנדרטיזציה של המשתנים לפני LASSO כדי שהקנס יחול באופן הוגן על כל מקדם. מבנה המועמדים: `age`, `sqrt_income` ושני משתני `dummy` לעיר (Jerusalem, TLV עם Haifa כקבוצת הייחוס), בתוספת שני איברי אינטראקציה ביניהם.

Best lambda (CV):	0.0843
LASSO coefficients (standardized):	{'sqrt_income': np.float64(77.659), 'age': np.float64(-0.1928), 'city_jerusalem': np.float64(-10.8256), 'city_tlv': np.float64(0.0), 'sqrt_income_jerusalem': np.float64(-16.8603), 'sqrt_income_tlv': np.float64(-38.7426)}
Selected variables:	['sqrt_income', 'age', 'city_jerusalem', 'sqrt_income_jerusalem', 'sqrt_income_tlv']

OLS Regression Results						
Dep. Variable:	psych		R-squared:	0.675		
Model:	OLS		Adj. R-squared:	0.673		
Method:	Least Squares		F-statistic:	411.6		
Date:	Sat, 16 May 2026		Prob (F-statistic):	4.26e-239		
Time:	00:22:43		Log-Likelihood:	-5249.4		
No. Observations:	999		AIC:	1.051e+04		
Df Residuals:	993		BIC:	1.054e+04		
Df Model:	5					
Covariance Type:	nonrobust					
	coef	std err	t	P> t	[0.025	0.975]
Intercept	210.0499	14.522	14.434	0.000	181.552	238.548
sqrt_income	103.7971	2.800	37.067	0.000	98.302	109.292
age	-0.0630	0.356	-0.177	0.860	-0.761	0.635
city_jerusalem	-21.3974	16.998	-1.259	0.208	-54.753	11.958
sqrt_income_jerusalem	-10.2317	4.758	-2.150	0.032	-19.568	-0.895
sqrt_income_tlv	-20.0254	1.061	-18.882	0.000	-22.107	-17.944
Omnibus:	1.711		Durbin-Watson:		1.940	
Prob(Omnibus):	0.425		Jarque-Bera (JB):		1.599	
Skew:	-0.093		Prob(JB):		0.449	
Kurtosis:	3.062		Cond. No.		403.	

תוצאות Relaxed LASSO:

• $\lambda = 0.0843$

• LASSO השאיר 5 משתנים:

city_tlv, sqrt_income_tlv, sqrt_income_jerusalem, city_jerusalem, age, sqrt_income אופס.

• $\bar{R}^2 = 0.673$ זהה ל Stepwise AIC.

השוואה ל Stepwise AIC:

• Stepwise AIC: sqrt_income + C(city) + C(city):sqrt_income — מודל היררכי.

• Relaxed LASSO כלל את age (לא מובהק, $p = 0.860$) ואת sqrt_income_tlv ללא city_tlv - מפר את עקרון ההיררכיה.

• LASSO מטפל בכל מקדם בנפרד ואין לו מנגנון לכפות תלות בין מקדמים. גרסאות כמו Group LASSO

ו Hierarchical LASSO נועדו לפתור זאת.

מסקנה: שני המודלים שוויו-ערך בטיב ההתאמה לדאטה ($\bar{R}^2$ זהה), אך נבדלים מבנית. Stepwise AIC עדיף — היררכי, פרסימוני, וללא משתנים לא מובהקים.

Q3

1. עבור מערך הנתונים הטיטאניק. עבור המודל המלא המכיל את המחלקה, המין, הגיל ואת איבר האינטראקציה בין מין לגיל - השתמשו ב-bootstrap הלא פרמטרי כדי לחשב את רווחי הסמך ברמת 95% של כל מקדמי המודל. שרטטו את התפלגויות ה-bootstrap והשוו את התוצאות לרווחי הסמך האנליטיים מפלט המודל הסטנדרטי.

המשתנה התלוי SURVIVED הוא בינארי, ולכן נשתמש ברגרסיה לוגיסטית. נסמן $p = P(\text{Survived} = 1)$. המודל המלא:

$$\ln\left(\frac{p}{1-p}\right) = \beta_0 + \beta_1 \cdot \text{PCLASS} + \beta_2 \cdot \text{SEX} + \beta_3 \cdot \text{AGE} + \beta_4 \cdot (\text{SEX} \times \text{AGE})$$

Nonparametric Bootstrap פועל באופן הבא:

a. דוגמים מהדאטה המקורי דגימה חדשה בגודל n עם החזרה.

b. מתאימים את המודל על הדגימה ושומרים את המקדמים.

c. חוזרים על התהליך B פעמים.

d. רווח הסמך ברמת 95% מתקבל מהאחוזונים 2.5% ו 97.5% של ההתפלגות הבוטסטראפית של כל מקדם.

רווחי הסמך האנליטיים מהפלט הסטנדרטי מסתמכים על נורמליות אסימפטוטית של ה MLE. ה Bootstrap לא דורש הנחה זו, ולכן השוואה ביניהם מאששת או מערערת את תקפות ההנחות האסימפטוטיות.


Sample size: 679

	ID	NAME	PCLASS	AGE	SEX	SURVIVED
0	1	Allen, Miss Elisabeth Walton	1	29.0000	1	1
1	2	Allison, Miss Helen Loraine	1	2.0000	1	0
2	3	Allison, Mr Hudson Joshua Creighton	1	30.0000	0	0
3	4	Allison, Mrs Hudson JC (Bessie Waldo Daniels)	1	25.0000	1	0
4	5	Allison, Master Hudson Trevor	1	0.9200	0	1

Logit Regression Results						
Dep. Variable:		SURVIVED		No. Observations:		679
Model:		Logit		Df Residuals:		674
Method:		MLE		Df Model:		4
Date:		Sat, 16 May 2026		Pseudo R-squ.:		0.3650
Time:		10:22:26		Log-Likelihood:		-295.29
converged:		True		LL-Null:		-465.06
Covariance Type:		nonrobust		LLR p-value:		3.198e-72
	coef	std err	z	P> z	[0.025	0.975]
Intercept	3.3674	0.517	6.516	0.000	2.354	4.380
PCLASS	-1.3143	0.154	-8.531	0.000	-1.616	-1.012
SEX	0.7242	0.473	1.531	0.126	-0.203	1.651
AGE	-0.0708	0.011	-6.602	0.000	-0.092	-0.050
SEX:AGE	0.0723	0.016	4.602	0.000	0.042	0.103

Successful bootstrap iterations:	2000
----------------------------------	------

	Coefficient	Bootstrap _Mean	Analytical _Lower	Analytical _Upper	Bootstrap _Lower	Bootstrap _Upper
Intercept	3.3674	3.3934	2.3545	4.3803	2.4221	4.4512
PCLASS	-1.3143	-1.3271	-1.6162	-1.0123	-1.6766	-1.0193
SEX	0.7242	0.7257	-0.2030	1.6513	-0.1851	1.6558
AGE	-0.0708	-0.0714	-0.0918	-0.0497	-0.0932	-0.0510
SEX:AGE	0.0723	0.0736	0.0415	0.1031	0.0438	0.1056



השוואת רווחי הסמך:

- Intercept: [2.35, 4.38] אנליטי לעומת [2.42, 4.45] בוטסטראפ.
- PCLASS: [-1.62, -1.01] אנליטי לעומת [-1.68, -1.02] בוטסטראפ.
- SEX: [-0.20, 1.65] אנליטי לעומת [-0.19, 1.66] בוטסטראפ.
- AGE: [-0.092, -0.050] אנליטי לעומת [-0.093, -0.051] בוטסטראפ.
- SEX:AGE: [0.042, 0.103] אנליטי לעומת [0.044, 0.106] בוטסטראפ.

רווחי הסמך הבוטסטראפיים והאנליטיים כמעט זהים בכל המקדמים. ההתאמה הזו מצביעה על כך שהתפלגות הבוטסטראפ של כל מקדם סימטרית ומרוכזת, בהתאם לנורמליות האסימפטוטית של MLE. גודל המדגם ($n = 679$) מספיק להבטחת אסימפטוטיקה טובה.

מסקנות לגבי מובהקות:

- AGE, PCLASS ו SEX:AGE מובהקים — רווחי הסמך אינם כוללים את 0.
- SEX לבדו לא מובהק — רווח הסמך כולל את 0. האפקט של מין על הישרדות מתבטא דרך האינטראקציה עם גיל, לא כאפקט עיקרי בלבד.
- קיומה של אינטראקציה מובהקת בין SEX ל AGE מסביר מדוע SEX לבדו אינו מובהק — ההשפעה של מין על הישרדות תלויה בגיל.

גרפי ה Bootstrap מראים התפלגויות סימטריות וקרובות לנורמליות עבור כל המקדמים, מה שמחזק את האמינות של רווחי הסמך האנליטיים.

א. השתמשו באלגוריתם הרשת האלסטית עם $\alpha=0.7$, ו-CV פי 15 לכוון בחירת הפרמטרים. דווחו והשוו את התוצאות שלכם למודל הרגרסיה השלבית הטוב ביותר של קריטריון AIC.

Elastic Net הוא שילוב של LASSO ו Ridge. פונקציית הקנס:

$$\lambda[\alpha \sum_j |\beta_j| + (1 - \alpha) \sum_j \beta_j^2]$$

כאשר $\alpha = 1$ מקבלים LASSO טהור, $\alpha = 0$ מקבלים Ridge טהור, ועם $\alpha = 0.7$ הקנס הוא 70% L1 ו 30% L2. שילוב זה מאפשר בחירת משתנים (כמו LASSO) תוך טיפול טוב יותר במולטיקוליניאריות (כמו Ridge). מאחר שהמשתנה התלוי בינארי, נשתמש ב Logistic Elastic Net. בחירת פרמטר הכוון נעשית באמצעות 15 fold CV.

נשווה את התוצאות למודל Stepwise AIC עם אותם משתנים מועמדים: SEX:AGE ו PCLASS, SEX, AGE.

Logit Regression Results						
Dep. Variable:	SURVIVED		No. Observations:	679		
Model:	Logit		Df Residuals:	674		
Method:	MLE		Df Model:	4		
Date:	Sat, 16 May 2026		Pseudo R-squ.:	0.3650		
Time:	11:06:56		Log-Likelihood:	-295.29		
converged:	True		LL-Null:	-465.06		
Covariance Type:	nonrobust		LLR p-value:	3.198e-72		
	coef	std err	z	P> z	[0.025	0.975]
Intercept	3.3674	0.517	6.516	0.000	2.354	4.380
PCLASS	-1.3143	0.154	-8.531	0.000	-1.616	-1.012
SEX	0.7242	0.473	1.531	0.126	-0.203	1.651
AGE	-0.0708	0.011	-6.602	0.000	-0.092	-0.050
SEX:AGE	0.0723	0.016	4.602	0.000	0.042	0.103

Best C (CV):	0.2336
Best lambda:	4.2813
Elastic Net coefficients (standardized):	{ 'PCLASS': np.float64(-0.973), 'SEX': np.float64(0.4581), 'AGE': np.float64(-0.8626), 'SEX_AGE': np.float64(1.0256) }
Selected variables:	['PCLASS', 'SEX', 'AGE', 'SEX_AGE']


תוצאות Elastic Net:

- פרמטר הכונון שנבחר ב 15 fold CV: $\lambda = 4.28$.
 - Elastic Net השאיר את כל 4 המשתנים: SEX, AGE, PCLASS, SEX_AGE.
 - המקדמים הסטנדרטיים של (PCLASS: -0.97, SEX: 0.46, AGE: -0.86, SEX_AGE: 1.03), Elastic Net מצמצמים יחסית, כצפוי מרגולריזציה. לאחר שלב ההרפיה (OLS ללא קנס), המקדמים חוזרים לערכים של המודל המלא.
 - שלב ההרפיה זהה לחלוטין למודל Stepwise AIC המוצג למעלה.
 - השוואה ל Stepwise AIC:
 - שתי השיטות בחרו באותם 4 משתנים, Pseudo $R^2 = 0.365$ – $AIC = 600.59$.
 - שלוש שיטות שונות – גרסיה לוגיסטית רגילה (סעיף 3.1), Elastic Net ו Stepwise AIC - סכימות על אותו מודל.
- מסקנה: כל המשתנים בדאטה תורמים מובהקית להסבר ההישרדות. SEX לבדו אינו מובהק ($p = 0.126$), אך נכלל במודל בגלל עקרון ההיררכיה והאינטראקציה המובהקת עם AGE. ההסכמה בין השיטות מחזקת את הביטחון בבחירה.
- ב. השתמשו ב-BS הלא פרמטרי כדי לבנות רווחי סמך ברמת 95% עבור המקדמים שאינם אפס של המודל הסופי. סכמו את התוצאות.

נבצע Nonparametric Bootstrap עבור המודל שנבחר ב Elastic Net. מאחר שכל 4 המקדמים שונים מאפס, נחשב רווחי סמך עבור כולם. בכל איטרציה: דוגמים מהדאטה עם החזרה, מריצים מחדש את ה Elastic Net עם אותם פרמטרים ($\alpha = 0.7$, λ קבוע מ CV), ושומרים את המקדמים. רווח הסמך ברמת 95% מתקבל מהאחוזונים 2.5%-ו 97.5%.

Successful bootstrap iterations: 1000

	Original_Coef	Bootstrap_Mean	CI_Lower_2.5%	CI_Upper_97.5%	Includes_Zero
PCLASS	-0.9730	-0.9819	-1.2303	-0.7423	False
SEX	0.4581	0.4675	0.1088	0.8371	False
AGE	-0.8626	-0.8643	-1.1114	-0.6062	False
SEX_AGE	1.0256	1.0320	0.6405	1.4307	False



תוצאות Nonparametric Bootstrap על מקדמי Elastic Net 1000 (איטרציות):

- $PCLASS: \hat{\beta} = -0.973$ 95% CI $[-1.23, -0.74]$. מובהק.

- $SEX: \hat{\beta} = 0.458$ 95% CI $[0.11, 0.84]$. מובהק.

- $AGE: \hat{\beta} = -0.863$ 95% CI $[-1.11, -0.61]$. מובהק.

- $SEX: AGE: \hat{\beta} = 1.026$ 95% CI $[0.64, 1.43]$. מובהק.

כל ארבעת המקדמים מובהקים — אף אחד מרווחי הסמך לא כולל את 0.

השוואת עוצמת ההשפעה (על המקדמים הסטנדרטיים):

- $SEX: AGE$ — עוצמה 1.03, האפקט החזק ביותר במודל.

- $PCLASS$ — עוצמה 0.97, השפעה שלילית חזקה.

- AGE — עוצמה 0.86, השפעה שלילית.

- SEX — עוצמה 0.46, החלש מבין הארבעה אך עדיין מובהק.

הערה על SEX : ב 3.1 הוא לא היה מובהק, ובאן כן. הסיבה: הקנס של Elastic Net מקטין את שונות האומדן בין

דגימות Bootstrap, ולכן רווח הסמך צר יותר. אין סתירה — שני אומדנים שונים של אותו פרמטר.

מסקנה: $SEX: AGE$ הוא האפקט החזק ביותר במודל, ואחריו PCLASS. דפוס "נשים וילדים תחילה" משתקף בנתונים.

יהי $y_i = \beta x_i + \epsilon_i, i = 1, \dots, n$, כאשר $\text{Var}(\epsilon_i|x) = \sigma^2, E[\epsilon_i|x] = 0$, $\text{cov}(\epsilon_i, \epsilon_j) = 0$ עבור כל $j \neq i$.

1. מצא את אומדן OLS, את הערך הצפוי שלו, השונות שלו והראה את העקביות שלו.

שלב 1 — גזירת אומדן OLS:

שיטת הריבועים הפחותים מחפשת את β שממזער את סכום ריבועי השאריות:

$$S(\beta) = \sum_{i=1}^n (y_i - \beta x_i)^2$$

נגזור לפי β ונשווה לאפס:

$$\frac{\partial S}{\partial \beta} = -2 \sum_{i=1}^n x_i (y_i - \beta x_i) = 0$$

פותחים סוגריים ומבודדים את β :

$$\sum_{i=1}^n x_i y_i = \beta \sum_{i=1}^n x_i^2$$

$$\hat{\beta}_{OLS} = \frac{\sum_{i=1}^n x_i y_i}{\sum_{i=1}^n x_i^2}$$

בכתיב מטריצי, עם $X = (x_1, \dots, x_n)^T$ כווקטור עמודה:

$$\hat{\beta}_{OLS} = (X^T X)^{-1} X^T y$$

הביטוי $X^T X = \sum x_i^2$ הוא סקלר, ו $X^T y = \sum x_i y_i$, כך ששתי הצורות זהות.

שלב 2 — תוחלת:

נציב $y_i = \beta x_i + \epsilon_i$:

$$\hat{\beta}_{OLS} = \frac{\sum_{i=1}^n x_i (\beta x_i + \epsilon_i)}{\sum_{i=1}^n x_i^2} = \frac{\beta \sum_{i=1}^n x_i^2 + \sum_{i=1}^n x_i \epsilon_i}{\sum_{i=1}^n x_i^2} = \beta + \frac{\sum_{i=1}^n x_i \epsilon_i}{\sum_{i=1}^n x_i^2}$$

נחשב תוחלת מותנית ב x :

$$E[\hat{\beta}|x] = \beta + \frac{\sum_{i=1}^n x_i E[\epsilon_i|x]}{\sum_{i=1}^n x_i^2} = \beta + 0 = \beta$$

האומדן חסר הטיה.

שלב 3 – שונות:

מהביטוי $\hat{\beta} = \beta + \frac{\sum x_i \epsilon_i}{\sum x_i^2}$, השונות תלויה רק באיבר הימני:

$$\text{Var}(\hat{\beta}|x) = \text{Var}\left(\frac{\sum x_i \epsilon_i}{\sum x_i^2} \middle| x\right) = \frac{1}{(\sum x_i^2)^2} \sum x_i^2 \text{Var}(\epsilon_i|x)$$

השתמשנו באי-תלות בין השגיאות $\text{cov}(\epsilon_i, \epsilon_j)$. מאחר ש $\text{Var}(\epsilon_i|x) = \sigma^2$

$$\text{Var}(\hat{\beta}_{OLS}|x) = \frac{\sigma^2}{\sum_{i=1}^n x_i^2}$$

שלב 4 – עקיבות:

אומדן הוא עקיב אם הוא מתכנס בהסתברות לערך האמיתי כאשר $n \rightarrow \infty$. מאחר שהאומדן חסר הטיה, ה MSE שווה לשונות, ולכן מספיק להראות ששונות שואפת לאפס.

כאשר $n \rightarrow \infty$ הסכום $\sum x_i^2$ גדל לאינסוף, ולכן:

$$\text{Var}(\hat{\beta}) = \frac{\sigma^2}{\sum x_i^2} \xrightarrow{n \rightarrow \infty} 0$$

מאי-שוויון צ'בישב: אומדן חסר הטיה עם MSE השואף לאפס מתכנס בהסתברות לפרמטר האמיתי, כלומר $\hat{\beta} \xrightarrow{P} \beta$ לכן האומדן עקיב.

2. מצא את אומדן Ridge כאשר $r \leq \beta^2$, את הערך הצפוי שלו, השונות שלו והראה את העקביות שלו.

שלב 1 – גזירת אומדן Ridge:

בעיית האופטימיזציה היא מינימיזציה של סכום ריבועי השאריות עם אילוץ על גודל המקדם:

$$\min_{\beta} \sum_{i=1}^n (y_i - \beta x_i)^2$$

בהינתן

$$\beta^2 \leq r$$

באמצעות כופלי לגרנז', הבעיה שקולה למינימיזציה הלא-מוגבלת:

$$L(\beta) = \sum_{i=1}^n (y_i - \beta x_i)^2 + \lambda \beta^2$$

כאשר $\lambda \geq 0$ הוא פרמטר הרגולריזציה. נגזור לפי β ונשווה לאפס:

$$\frac{\partial L}{\partial \beta} = -2 \sum_{i=1}^n x_i (y_i - \beta x_i) + 2\lambda \beta = 0$$

פותרים סוגריים ומבודדים את β :

$$\sum_{i=1}^n x_i y_i = \beta \left(\sum_{i=1}^n x_i^2 + \lambda \right)$$

$$\hat{\beta}_{\text{Ridge}} = \frac{\sum_{i=1}^n x_i y_i}{\sum_{i=1}^n x_i^2 + \lambda}$$

בכתיב מטריצי:

$$\hat{\beta}_{\text{Ridge}} = (X^T X + \lambda I)^{-1} X^T y$$

שלב 2 – תוחלת:

$$y_i = \beta x_i + \epsilon_i$$

$$\hat{\beta}_{\text{Ridge}} = \frac{\sum x_i (\beta x_i + \epsilon_i)}{\sum x_i^2 + \lambda} = \frac{\beta \sum x_i^2 + \sum x_i \epsilon_i}{\sum x_i^2 + \lambda}$$

נחשב תוחלת מותנית ב x :

$$E[\hat{\beta}_{\text{Ridge}} | x] = \frac{\beta \sum x_i^2 + \sum x_i E[\epsilon_i | x]}{\sum x_i^2 + \lambda} = \frac{\beta \sum x_i^2}{\sum x_i^2 + \lambda}$$

בניגוד ל OLS, אומדן Ridge הוא מוטה. ההטיה היא:

$$\text{Bias}(\hat{\beta}_{\text{Ridge}}) = E[\hat{\beta}_{\text{Ridge}}] - \beta = -\beta \cdot \frac{\lambda}{\sum x_i^2 + \lambda}$$

ההטיה היא כלפי 0 – בצפוי מקנס שמצמצם את גודל המקדם.

שלב 3 – שונות:

השונות תלויה רק באיבר המקרי $\sum x_i \epsilon_i$

$$\text{Var}(\hat{\beta}_{\text{Ridge}} | x) = \text{Var}\left(\frac{\sum x_i \epsilon_i}{\sum x_i^2 + \lambda} \mid x\right) = \frac{1}{(\sum x_i^2 + \lambda)^2} \sum x_i^2 \text{Var}(\epsilon_i | x)$$

מאחר ש $\text{Var}(\epsilon_i | x) = \sigma^2$

$$\text{Var}(\hat{\beta}_{\text{Ridge}} | x) = \frac{\sigma^2 \sum x_i^2}{(\sum x_i^2 + \lambda)^2}$$

בהשוואה ל OLS – שונות OLS היא $\frac{\sigma^2}{\sum x_i^2}$. שונות Ridge קטנה יותר כאשר $\lambda > 0$, כלומר השונות פוחתת על חשבון

ההטיה. זוהי תופעת ה bias-variance tradeoff הקלאסית של רגולריזציה.

שלב 4 – עקיבות:

נניח ש λ קבוע (לא תלוי ב n). ראה ששני המרכיבים של ה MSE – ההטיה והשונות – שואפים לאפס.

ההטיה: כאשר $n \rightarrow \infty$ הסכום $\sum x_i^2$ גדל לאינסוף, ולכן:

$$\text{Bias} = -\beta \frac{\lambda}{\sum x_i^2 + \lambda} \xrightarrow{n \rightarrow \infty} 0$$

השונות:

$$\text{Var}(\hat{\beta}_{\text{Ridge}}) = \frac{\sigma^2 \sum x_i^2}{(\sum x_i^2 + \lambda)^2} \xrightarrow{n \rightarrow \infty} 0$$

ה $\text{MSE} = \text{Bias}^2 + \text{Variance}$ שואף לאפס. לכן מאי-שוויון צ'בישב, $\hat{\beta}_{\text{Ridge}} \xrightarrow{P} \beta$ — האומדן עקיב.

3. מצא את אומדן ה-LASSO כאשר $|\beta| \leq r$, ערכו הצפוי, והראה את עקביותו.

שלב 1 — גזירת אומדן LASSO:

בעיית האופטימיזציה היא:

$$\min_{\beta} \sum_{i=1}^n (y_i - \beta x_i)^2$$

בהינתן

$$|\beta| \leq r$$

באמצעות כופלי לגרנד:

$$L(\beta) = \sum_{i=1}^n (y_i - \beta x_i)^2 + 2\lambda|\beta|$$

בניגוד ל Ridge, פונקציית הקנס אינה גזירה ב $\beta = 0$, ולכן מטפלים בשלושה מקרים בנפרד.

מקרה 1 — $\beta > 0$ הנגזרת של $|\beta|$ היא 1.

$$\frac{\partial L}{\partial \beta} = -2 \sum x_i (y_i - \beta x_i) + 2\lambda = 0$$

$$\hat{\beta}_{\text{LASSO}} = \frac{\sum x_i y_i - \lambda}{\sum x_i^2} = \hat{\beta}_{\text{OLS}} - \frac{\lambda}{\sum x_i^2}$$

מקרה 2 — $\beta < 0$ הנגזרת של $|\beta|$ היא -1.

$$\hat{\beta}_{\text{LASSO}} = \frac{\sum x_i y_i + \lambda}{\sum x_i^2} = \hat{\beta}_{\text{OLS}} + \frac{\lambda}{\sum x_i^2}$$

מקרה 3 — $\beta = 0$: זה קורה כאשר $|\hat{\beta}_{\text{OLS}}| \leq \frac{\lambda}{\sum x_i^2}$, כלומר כאשר אומדן OLS קטן מהסף.

סיכום: אומדן LASSO לוקח את אומדן OLS, ומקטין אותו לכיוון 0 בגודל הסף $\frac{\lambda}{\sum x_i^2}$. אם $\hat{\beta}_{\text{OLS}}$ קטן מהסף בערך מוחלט,

האומדן מתאפס לחלוטין.

שלב 2 — תוחלת:

בניגוד ל Ridge, לאומדן LASSO אין צורה אנליטית פשוטה לתוחלת, משום שהפתרון משתנה לפי הסימן של $\hat{\beta}_{\text{OLS}}$ ולפי

הגודל היחסי שלו ביחס לסף.

האומדן מוטה כלפי 0 בגלל שילוב של שני מנגנונים:

- כיווץ — כאשר $|\hat{\beta}_{OLS}| > \frac{\lambda}{\sum x_i^2}$, האומדן מצומצם בגודל הסף לכיוון 0.
 - איפוס — כאשר $|\hat{\beta}_{OLS}|$ קטן מהסף, האומדן ייאפס לחלוטין — גם אם β האמיתי שונה מ 0.
- ההטיה היא המחיר של בחירת המשתנים — (variable selection) תכונה שייחודית ל LASSO-ביחס ל Ridge.
- שלב 3 — עקיבות:

נראה ש LASSO עקיב תחת התנאים הסטנדרטיים. נשים לב:

- אומדן OLS עקיב — ראינו זאת בסעיף 1 — כלומר $\hat{\beta}_{OLS} \xrightarrow{P} \beta$.
 - הסף 0 $\frac{\lambda}{\sum x_i^2} \xrightarrow{n \rightarrow \infty} 0$ עבור λ קבוע, כי $\sum x_i^2 \rightarrow \infty$.
- אומדן LASSO הוא $\hat{\beta}_{OLS}$ אחרי הקטנה (או איפוס) בגודל הסף — פעולה רציפה. ממשפט המיפוי הרציף (Continuous Mapping Theorem): מאחר ש $\hat{\beta}_{OLS} \xrightarrow{P} \beta$ והסף שואף ל-0, אומדן LASSO מתכנס גם ל β :

$$\hat{\beta}_{LASSO} \xrightarrow{P} \beta$$

זה תקף לכל ערך של β — כולל $\beta = 0$, שבו האומדן מתכנס ל 0. לכן האומדן עקיב.

Q5

ה-AIC מוגדר כ-

$$AIC = -2\log(\text{Likelihood}) + 2p$$

כאשר p הוא מספר פרמטרי המודל. הראו שעבור מודל הרגרסיה המרובה הליניארית

$$y_i = \beta_0 + \beta_1 x_{1i} + \dots + \beta_p x_{pi} + \epsilon_i, i = 1, \dots, n$$

עם ההנחות הקלאסיות על איבר השגיאה, כלומר,

$$\epsilon_i \sim^{iid} N(0, \sigma^2), i = 1, \dots, n$$

מסתכמים ב

$$AIC = n\log(\hat{\sigma}_{MLE}^2) + C_{n,p}$$

כאשר $\hat{\sigma}_{MLE}^2$ הוא אומדן הסבירות המקסימלית של σ^2 , ו $C_{n,p}$ הוא מונח שתלוי רק בגודל המדגם n ובמספר הפרמטרים p .

שלב 1 — כתיבת פונקציית הסבירות (Likelihood):

תחת ההנחה $\epsilon_i \sim^{iid} N(0, \sigma^2)$, מתקיים $y_i \sim N(\mu_i, \sigma^2)$ כאשר $\mu_i = \beta_0 + \beta_1 x_{1i} + \dots + \beta_p x_{ip}$. פונקציית הצפיפות של

כל תצפית היא:

$$f(y_i) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(y_i - \mu_i)^2}{2\sigma^2}}$$

מאחר שהתצפיות בלתי תלויות, פונקציית הסבירות היא מכפלה:

$$L(\beta, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(y_i - \mu_i)^2}{2\sigma^2}}$$

$$L(\beta, \sigma^2) = \left(\frac{1}{\sqrt{2\pi\sigma^2}} \right)^n e^{-\sum \frac{(y_i - \mu_i)^2}{2\sigma^2}}$$

$$L(\beta, \sigma^2) = (2\pi\sigma^2)^{-\frac{n}{2}} e^{-\frac{1}{2\sigma^2} \sum (y_i - \mu_i)^2}$$

שלב 2 – חישוב log-likelihood:

$$l = \log(L) = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\sigma^2) - \frac{1}{2\sigma^2} \sum (y_i - \mu_i)^2$$

שלב 3 – הצבת אומדן ה MLE של σ^2 :

אומדן ה MLE של σ^2 במודל רגרסיה ליניארית הוא:

$$\hat{\sigma}_{MLE}^2 = \frac{1}{n} \sum (y_i - \mu_i)^2 = \frac{RSS}{n}$$

כלומר $\sum (y_i - \mu_i)^2 = n\sigma_{MLE}^2$. נציב ל (בנקודת המקסימום):

$$l_{\max} = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\hat{\sigma}_{MLE}^2) - \frac{1}{2\hat{\sigma}_{MLE}^2} \cdot n\hat{\sigma}_{MLE}^2$$

$$l_{\max} = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\hat{\sigma}_{MLE}^2) - \frac{n}{2}$$

שלב 4 – הצבה ב AIC:

$$AIC = -2l_{\max} + 2p$$

$$AIC = -2 \left[-\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\hat{\sigma}_{MLE}^2) - \frac{n}{2} \right] + 2p$$

$$AIC = n \log(2\pi) + n \log(\hat{\sigma}_{MLE}^2) + n + 2p$$

נסדר:

$$AIC = n \log(\hat{\sigma}_{MLE}^2) + n \log(2\pi) + n + 2p$$

נסמן את האיברים שאינם תלויים ב $\hat{\sigma}_{MLE}^2$

$$C_{n,p} = n \log(2\pi) + n + 2p$$

ולכן:

$$AIC = n \log(\hat{\sigma}_{MLE}^2) + C_{n,p}$$

שלב 5 – סיכום:

הגענו לצורה הדרושה. $C_{n,p}$ הוא קבוע התלוי רק ב n וב p ולא בנתונים. כלומר, למטרות השוואה בין מודלים על אותם נתונים,

$C_{n,p}$ משתנה רק בגלל p , ולכן בחירת המודל לפי AIC מצטמצמת למינימיזציה של $n \log(\hat{\sigma}_{MLE}^2) + 2p$

1. תהא $X \sim DU[1, N]$. גזרו את הערך הצפוי ואת השונות של X .

$X \sim DU[1, N]$ פירושו ש X מקבל את הערכים $1, 2, \dots, N$ עם הסתברות שווה $P(X = k) = \frac{1}{N}$ לכל $k \in \{1, \dots, N\}$

שלב 1 — חישוב הערך הצפוי:

לפי הגדרת התוחלת:

$$E[X] = \sum_{k=1}^N k \cdot P(X = k) = \sum_{k=1}^N k \cdot \frac{1}{N} = \frac{1}{N} \sum_{k=1}^N k$$

נשתמש בנוסחה הידועה לסכום מספרים טבעיים: $\sum_{k=1}^N k = \frac{N(N+1)}{2}$ לכן:

$$E[X] = \frac{1}{N} \cdot \frac{N(N+1)}{2} = \frac{N+1}{2}$$

שלב 2 — חישוב המומנט השני $E[X^2]$:

$$E[X^2] = \sum_{k=1}^N k^2 \cdot P(X = k) = \frac{1}{N} \sum_{k=1}^N k^2$$

נשתמש בנוסחה לסכום ריבועים: $\sum_{k=1}^N k^2 = \frac{N(N+1)(2N+1)}{6}$ לכן:

$$E[X^2] = \frac{1}{N} \cdot \frac{N(N+1)(2N+1)}{6} = \frac{(N+1)(2N+1)}{6}$$

שלב 3 — חישוב השונות:

לפי הזהות $\text{Var}(X) = E[X^2] - (E[X])^2$:

$$\text{Var}(X) = \frac{(N+1)(2N+1)}{6} - \left(\frac{N+1}{2}\right)^2$$

נוציא גורם משותף $(N+1)$:

$$\text{Var}(X) = (N+1) \left[\frac{2N+1}{6} - \frac{N+1}{4} \right]$$

נאחד את השברים על מכנה משותף 12:

$$\text{Var}(X) = (N+1) \frac{2(2N+1) - 3(N+1)}{12} = (N+1) \frac{4N+2-3N-3}{12} = (N+1) \frac{N-1}{12}$$

ולכן:

$$\text{Var}(X) = \frac{(N+1)(N-1)}{12} = \frac{N^2-1}{12}$$

סיכום:

$$E[X] = \frac{N+1}{2} \quad \bullet$$

$$\text{Var}(X) = \frac{N^2-1}{12} \quad \bullet$$

2. תהא n_1 ו n_2 מספר החולים בקבוצה הראשונה והשנייה, בהתאמה. תהא Y משתנה התוצאה, ו R_1, R_2 סכום הדירוג בכל קבוצה, בהתאמה.

א. כתבו $R_1 + R_2$ במונחים של N , כאשר $n_1 + n_2 = N$.

כל אחת מ תצפיות מקבלת דירוג ייחודי מהקבוצה. כל דירוג מופיע בדיוק פעם אחת, ושייך לאחת משתי הקבוצות:

• R_1 — סכום הדירוגים של תצפיות מקבוצה 1.

• R_2 — סכום הדירוגים של תצפיות מקבוצה 2.

מאחר ששתי הקבוצות יחד כוללות את כל הדירוגים מ 1 עד :

$$R_1 + R_2 = \sum_{k=1}^N k = \frac{N(N+1)}{2}$$

ב. מצא את $E[R_1]$ ו- $E[R_2]$ תחת הנחת האפס של היעדר הבדלים בין חציוני הקבוצות.

תחת השערת האפס H_0 , אין הבדל בין התפלגויות שתי הקבוצות, ולכן הדירוגים מוקצים לתצפיות באופן אקראי.

שלב 1 — תוחלת של דירוג בודד:

תחת H_0 , דירוג של תצפית כלשהי מתפלג $DU[1, N]$. לפי סעיף 6א:

$$E[X] = \frac{N+1}{2}$$

שלב 2 — תוחלת של R_1 :

R_1 הוא סכום הדירוגים של n_1 תצפיות בקבוצה 1. לפי לינאריות התוחלת:

$$E[R_1] = n_1 \cdot \frac{N+1}{2} = \frac{n_1(N+1)}{2}$$

שלב 3 — תוחלת של R_2 :

באותו אופן:

$$E[R_2] = n_2 \cdot \frac{N+1}{2} = \frac{n_2(N+1)}{2}$$

שלב 4 — בדיקה:

$$E[R_1] + E[R_2] = \frac{(n_1 + n_2)(N+1)}{2} = \frac{N(N+1)}{2}$$

זה תואם לסעיף 2.ב. שבו ראינו ש $R_1 + R_2 = \frac{N(N+1)}{2}$ תמיד.